

## Reliable and trustworthy Artificial Intelligence

| Dataset | Attack type     | epsilon = 0.05 | epsilon = 0.1 | epsilon = 0.2 | epsilon = 0.3 |
|---------|-----------------|----------------|---------------|---------------|---------------|
| MNIST   | FGSM Targeted   | 0.0%           | 1.0%          | 18.0%         | 47.0%         |
| MNIST   | FGSM Untargeted | 3.0%           | 18.0%         | 61.0%         | 80.0%         |
| MNIST   | PGD Targeted    | 0.0%           | 3.0%          | 89.0%         | 100.0%        |
| MNIST   | PGD Untargeted  | 4.0%           | 45.0%         | 99.0%         | 100.0%        |
| CIFAR10 | FGSM Targeted   | 7.0%           | 5.0%          | 6.0%          | 4.0%          |
| CIFAR10 | FGSM Untargeted | 84.0%          | 88.0%         | 92.0%         | 88.0%         |
| CIFAR10 | PGD Targeted    | 100.0%         | 100.0%        | 100.0%        | 100.0%        |
| CIFAR10 | PGD Untargeted  | 100.0%         | 100.0%        | 100.0%        | 100.0%        |

Simple CNN(Conv1 -> ReLU -> MaxPool -> Conv2 -> ReLU -> MaxPool -> fc1 -> ReLU -> fc2), 과 ResNet20(Normalization)을 각각 MNIST와 CIFAR10 데이터셋에 대응되는 모델로 설정했다.

실험 결과 PGD는 k=40이 아니라 10임에도 MNIST에 대해서 epsilon이 커질수록 높은 성공률을 보였고 CIFAR10은 100%의 적중률을 보였다.

허나, FGSM방식은 CIFAR에서 targeted, Untargeted 상관없이 epsilon이 0.3이 되는 순간 성능이 저하됐는데 이는 clipping현상으로

보여진다. epsilon이 커져 pixel 값이  $[0, 1]$ 을 벗어나 노이즈의 방향성을 상실한 것으로 보인다.

epsilon이 커질수록 공격 성공률은 대체적으로 상승하지만, 그만큼 이미지에 노이즈가 강해져 사람의 육안으로도 쉽게 구분하기 힘들 정도로 변한 것을 알 수 있고, 이는 Attack Accuracy와 Imperceptibility 사이의 Trade off 관계이다.